



ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

ĐỒ ÁN TỐT NGHIỆP CỬ NHÂN: XÂY DỰNG CHATBOT HỎI ĐÁP QUY CHẾ SINH VIÊN

Sinh viên thực hiện : Lê Quang Đức
MSSV : 20227221 – MI2 01 K67
GVHD : TS. Ngô Thị Hiền

ONE LOVE. ONE FUTURE.



NỘI DUNG TRÌNH BÀY

1. Mở đầu
2. Cơ sở lý thuyết
3. Phân tích và thiết kế hệ thống
4. Thực nghiệm
5. Kết luận



1. Mở đầu

1. Mở đầu

Đặt vấn đề

- **Thách thức từ dữ liệu:** Hệ thống văn bản quy chế tại HUST có khối lượng lớn, phân tán và sử dụng ngôn ngữ hành chính phức tạp.
- **Hạn chế của giải pháp hiện có:**
 - **Tìm kiếm từ khóa:** Kết quả nhiều, không hiểu ngữ cảnh.
 - **LLM phổ quát (ChatGPT/Gemini):** Thường xuyên gặp lỗi "ảo giác" (Hallucination) – tự sinh thông tin sai lệch do thiếu dữ liệu nội bộ.

Mục tiêu đề án

- **Xây dựng hệ thống Agentic RAG:** Tích hợp mô hình ngôn ngữ lớn với đồ thị trạng thái (LangGraph) để tối ưu hóa việc tìm kiếm thông tin thông qua cơ chế truy xuất đa vòng (Multi-hop Retrieval) và duy trì ngữ cảnh hội thoại đa lượt.
- **Kiểm soát chất lượng câu trả lời:** Xây dựng cơ chế đánh giá độ tin cậy và phân loại ý định để hạn chế tối đa tình trạng "ảo giác", đảm bảo thông tin đưa ra luôn chính xác và có căn cứ rõ ràng từ nguồn tài liệu gốc.

2. Cơ sở lý thuyết

2. Cơ sở lý thuyết

Mô hình ngôn ngữ lớn

S = I like reading books


The diagram illustrates the sequence of words in a sentence: "I like reading books". The words "I like reading" are grouped under the label "Previous words" with a green bracket. The words "books" are grouped under the label "Predicted words" with a purple bracket. Arrows point from the words "I like reading" to the word "books", indicating the flow of the sequence.

$$P(S) = P(I) \times P(\text{like}|I) \times P(\text{reading} | I \text{ like}) \times P(\text{books} | I \text{ like reading})$$

2. Cơ sở lý thuyết


Attention Is All You Need

Scaled Dot-Product Attention




$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Multi-Head Attention



$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$


where $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$



2. Cơ sở lý thuyết


Chatbot

How A Rule-Based Chatbot Works




2. Cơ sở lý thuyết

Retrieval-Augmented Generation - RAG



2. Cơ sở lý thuyết


Agentic RAG




3. Phân tích và thiết kế hệ thống

3.1. Khảo sát thực tế

- Hệ thống Chatbot trên trang <https://qldt.hust.edu.vn/students>
- Ưu điểm: Giao diện thân thiện, tốc độ phản hồi nhanh, phục vụ 24/7
- Nhược điểm:



Không truy vết nguồn




Không hỗ trợ hỏi đa lượt

3.2. Phân tích bài toán và yêu cầu hệ thống


- **Đối tượng phục vụ:**
 - Nhóm sinh viên
 - Nhóm Đại học và bộ phận hỗ trợ
- **Yêu cầu chức năng:**
 - Tiếp nhận xử lý câu hỏi và đưa ra câu trả lời
 - Phân loại ý định truy vấn
 - Hỗ trợ truy xuất đa bước
 - Hỗ trợ hội thoại đa lượt
 - Quản lý cơ sở tri thức
- **Yêu cầu phi chức năng:**
 - Đảm bảo cân bằng được giữa hiệu năng và độ chính xác của câu trả lời.
 - Khả năng giám sát, giải thích và bảo trì

3.3. Kiến trúc tổng thể

Pha ngoại tuyến (Khởi tạo một lần duy nhất - Build Time)



Pha ngoại tuyến (Chạy mỗi lần người dùng truy vấn)



- **Pha ngoại tuyến** – Thiết kế cơ sở dữ liệu
- **Pha trực tuyến** – Xử lý truy vấn thời gian thực
 - Tầng xử lý dữ liệu
 - Tầng suy luận tác tử
 - Tầng bộ nhớ

3.4. Thiết kế cơ sở dữ liệu

- Bộ dữ liệu là các **Quy định và Biểu mẫu** thường dùng.
- Thu thập trên trang <https://sv-ctt.hust.edu.vn/> của đại học.

Các Quy định và Biểu mẫu thường dùng

Cập nhật: 11:09 25/11/2025

I. Các Quy định thường dùng

1. Qui chế đào tạo

- [Mới] Quy chế năm 2025 & Bản giới thiệu các điểm mới: [xem tại đây](#).
- (Cũ) Qui chế đào tạo ban hành năm 2023: [xem tại đây](#).

2. Qui định ngoại ngữ

- [Mới] Áp dụng từ khóa K70: [xem tại đây](#)
 - [Xem Inforgraphic tại đây](#)
- Áp dụng từ khóa K68: [xem tại đây](#)
- Áp dụng từ khóa K65: [xem tại đây](#)
- Áp dụng với khóa K63 & K64 (chương trình chuẩn): [xem tại đây](#)
- Áp dụng với các chương trình Elitech từ K62-K64: [xem tại đây](#)

3.4. Thiết kế cơ sở dữ liệu

- Văn bản có header và footer gây nhiễu.
- Văn bản có cấu trúc chặt chẽ với nhau.
- Có nhiều dữ liệu dạng bảng

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC BÁCH KHOA HÀ NỘI

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập - Tự do - Hạnh phúc

Số: 5445 /QĐ-ĐHBK

Hà Nội, ngày 28 tháng 5 năm 2025

QUYẾT ĐỊNH **Về việc ban hành Quy chế đào tạo của Đại học Bách khoa Hà Nội**

GIÁM ĐỐC ĐẠI HỌC BÁCH KHOA HÀ NỘI

Căn cứ Luật Giáo dục đại học ngày 18 tháng 6 năm 2012 và Luật sửa đổi, bổ sung một số điều của Luật Giáo dục đại học ngày 19 tháng 11 năm 2018;

Căn cứ Nghị định số 99/2019/NĐ-CP ngày 30 tháng 12 năm 2019 của Chính phủ về việc Quy định chi tiết và hướng dẫn thi hành một số điều của Luật sửa đổi, bổ sung một số điều của Luật Giáo dục đại học;

Căn cứ Thông tư số 08/2021/TT-BGDĐT ngày 18 tháng 03 năm 2021 của Bộ Giáo dục và Đào tạo ban hành Quy chế đào tạo trình độ đại học;

Điều 2. Quyết định này có hiệu lực kể từ ngày ký. Các Ông/Bà Trưởng Ban Đào tạo, Trưởng các đơn vị được giao nhiệm vụ thực hiện đào tạo, các đơn vị có liên quan, các cán bộ viên chức, sinh viên, học viên và nghiên cứu sinh của Đại học Bách khoa Hà Nội chịu trách nhiệm thi hành Quyết định này. *HL*

Nơi nhận:

- Như Điều 2;
- Lưu: VT, ĐT.

KT. GIÁM ĐỐC
PHÓ GIÁM ĐỐC

PGS.TS. Nguyễn Phong Điền

CHƯƠNG I **NHỮNG QUY ĐỊNH CHUNG**

Điều 1. Phạm vi điều chỉnh và đối tượng áp dụng


1. Quy chế này quy định về công tác đào tạo đối với các khóa đào tạo theo hình thức chính quy, vừa làm vừa học (VLVH) và cấp văn bằng cử nhân, kỹ sư, thạc sĩ hoặc tiến sĩ của Đại học Bách khoa Hà Nội (ĐHBK Hà Nội). Những vấn đề không được đề cập đến trong Quy chế này sẽ được áp dụng theo các quy chế đào tạo do Bộ Giáo dục và Đào tạo (Bộ GDĐT) ban hành ^{1 2 3}.

6. Thời gian và khối lượng học tập chuẩn đối với các CTĐT theo hình thức chính quy không kể các học phần bổ sung kiến thức được quy định như sau:

Chương trình	Người học	Thời gian	Khối lượng tối thiểu
Cử nhân	Tốt nghiệp THPT	4 năm	132 tín chỉ
Kỹ sư	Tốt nghiệp cử nhân theo chương trình tích hợp	1,5 năm	48 tín chỉ
	Tốt nghiệp cử nhân	2 năm	60 tín chỉ
Thạc sĩ	Tốt nghiệp cử nhân	2 năm	60 tín chỉ
	Tốt nghiệp cử nhân theo chương trình tích hợp	1,5 năm	48 tín chỉ
Tiến sĩ	Tốt nghiệp thạc sĩ	3 năm	106 tín chỉ
	Tốt nghiệp đại học	4 năm	151 tín chỉ

7. Thời gian theo kế hoạch học tập chuẩn toàn khóa đối với hình thức đào tạo vừa làm vừa học dài hơn tối thiểu 20% so với hình thức đào tạo chính quy của cùng CTĐT.

3.4. Thiết kế cơ sở dữ liệu



3.5. Thiết kế tầng xử lý dữ liệu

Cổng tiền xử lý – Thiết kế tập luật nghiệp vụ

Dữ liệu quy chế Đại học Bách khoa Hà Nội sẽ được chia thành hai nhóm ý định như sau:

- **Nhóm ý định độc lập** – VD: quy định chung, mức học bổng, hướng dẫn chung,...
- **Nhóm ý định phụ thuộc** – VD: học phí, điều kiện đầu ra, ngoại ngữ,...

Cấu trúc của một ý định trong **nhóm ý định phụ thuộc**

LANGUAGE_REQUIREMENT:

description: "Yêu cầu ngoại ngữ đầu vào, chuẩn đầu ra theo ngành và khóa"

requires_entities: true

required_fields:

- ngành_hoc # Ví dụ: "CNTT", "Cơ điện tử", "Toán - Tin"

- khoa_hoc # Ví dụ: "K65", "K68", "K70"

clarification_template: "Để tra cứu yêu cầu ngoại ngữ chính xác, bạn vui lòng cho biết:

-Ngành học của bạn là gì? (ví dụ: CNTT, Cơ điện tử, Toán - Tin...)

-Bạn thuộc khóa nào? (ví dụ: K65, K68, K70...)"

examples:


- "Yêu cầu tiếng Anh ngành CNTT K65 là gì?"

- "Chuẩn đầu ra ngoại ngữ của Cơ điện tử K68?"

- "Tôi học Toán - Tin K70, cần TOEIC bao nhiêu?"

3.5. Thiết kế tầng xử lý dữ liệu

Cổng tiền xử lý – Kiến trúc phân loại



3.5. Thiết kế tăng xử lý dữ liệu

Cổng hậu xử lý

Đánh giá dựa trên ba yếu tố:

- **Chất lượng truy xuất (30%):** Dựa vào **số lượng tài liệu** liên quan tìm được (≥ 3 tài liệu đạt điểm tối đa).
- **Chất lượng tạo sinh (40%):** Đánh giá nội dung câu trả lời có **tính cụ thể** (chứa con số, tỷ lệ, thời gian - 20%) và có **trích dẫn căn cứ pháp lý** rõ ràng (Điều, Khoản - 20%).
- **Hiệu suất suy luận (30%):** Dựa vào **số vòng lặp**. Tìm thấy ngay ở vòng đầu tiên đạt tối đa 30%, càng lặp nhiều điểm càng giảm.


Dựa vào điểm số hệ thống sẽ đưa ra ba quyết định:

- **PASS ($\geq 65\%$):** Chấp nhận kết quả. Trả lời bình thường kèm nguồn trích dẫn minh bạch.
- **WARN (35% - 65%):** Mức độ tin cậy trung bình. Vẫn trả lời nhưng đính kèm **cảnh báo** yêu cầu sinh viên xác minh lại.
- **REJECT ($< 35\%$):** Điểm quá thấp. **Từ chối trả lời**, thông báo không có thông tin và gợi ý liên hệ trực tiếp phòng ban chuyên môn.

3.6. Thiết kế tầng suy luận tác tử

Điều phối bằng đồ thị trạng thái

- Áp dụng **LangGraph** để mô hình hóa luồng suy luận thành một Đồ thị trạng thái có hướng (**Directed Stateful Graph**).



- GraphState:** Một cấu trúc dữ liệu toàn cục đóng vai trò là "bộ nhớ chung", chia sẻ thông tin cho toàn bộ quá trình xử lý.

3.6. Thiết kế tăng suy luận tác tử

Điều phối bằng đồ thị trạng thái

- **Cấu trúc node:**


Quá trình được chia nhỏ cho 7 node hoạt động độc lập. Mỗi node chỉ đọc/ghi dữ liệu vào **GraphState**.

- **Cạnh điều kiện:**

Rẽ nhánh linh hoạt dựa trên trạng thái hiện tại.

- Nhánh 1: tại **Intent Gate**
- Nhánh 2: tại **Evaluate**


=> Tạo ra một **kiến trúc tự tinh chỉnh** cho đến khi tìm được câu trả lời chính xác nhất hoặc chạm ngưỡng giới hạn số vòng lặp.



3.6. Thiết kế tầng suy luận tác tử

Thiết kế các công cụ sử dụng

- Mọi công cụ trong hệ thống đều kế thừa từ lớp trừu tượng **BaseTool**



3.6. Thiết kế tầng suy luận tác tử

Thiết kế các công cụ sử dụng

RetrieveTool
+execute(query: str) ToolResult

- `top_k = 3; similarity_threshold = 0.35`

EvaluateTool
+execute(question: str, results: List, min_avg_sim: float, ...) ToolResult

- Tầng 1: `avg_sim >= 0.45`
- Tầng 2: gọi LLM đánh giá

RewriteTool
+execute(question: str, reason: str, memory_context: str) ToolResult

- Chỉ gọi khi EvaluateTool báo không có tài liệu và số vòng lặp ở mức cho phép.
- Viết lại thành truy vấn chuẩn luật

GenerateTool
+execute(question: str, results: List, memory_context: str) ToolResult


- Tổng hợp câu trả lời cuối cùng

3.7. Thiết kế tầng bộ nhớ

Cơ sở dữ liệu vector – Tri thức tĩnh

- Lưu trữ nguồn tri thức quy chế của Đại học
- **Chỉ đọc (Read-only)** trong toàn bộ quá trình vận hành trực tuyến (Pha trực tuyến). Cơ sở dữ liệu này chỉ được cập nhật ở Pha ngoại tuyến.
- Đảm bảo tính nhất quán tuyệt đối


Pha ngoại tuyến (Khởi tạo một lần duy nhất - Build Time)



3.7. Thiết kế tầng bộ nhớ

Bộ nhớ hội thoại – Tri thức động

- **Cửa sổ trượt – Sliding Window:** Duy trì ngữ cảnh giao tiếp đa lượt. Giới hạn lưu trữ K lượt hội thoại gần nhất
- **Kế thừa thực thể:** Tự động bóc tách thực thể và bảo lưu **Ý định** và **Thực thể** từ các cuộc hội thoại cũ



4. Thực nghiệm

4.1. Môi trường và cấu hình triển khai

- Cấu hình phần cứng

Thành phần	Cấu hình
CPU	Intel Core i5-11300H
RAM	16 GB DDR4
Ổ cứng	SSD 512 GB
GPU	Không sử dụng (mô hình embedding chạy trên CPU)
Hệ điều hành	Windows 11

- Tham số cấu hình hệ thống

```
retrieval:
  top_k: 3                # Số tài liệu trả về mỗi lần truy xuất
  similarity_threshold: 0.35 # Ngưỡng cosine similarity tối thiểu

agent:
  max_iterations: 5        # Số vòng lặp tối đa của đồ thị Agent
  high_confidence_threshold: 0.65 # Ngưỡng PASS của Confidence Gate ( $\geq 65\%$ )
  low_confidence_threshold: 0.35  # Ngưỡng REJECT của Confidence Gate ( $< 35\%$ )
  min_avg_similarity: 0.45      # Ngưỡng avg_sim để EvaluateTool kết luận đủ tài liệu

memory:
  window_size: 5          # Số lượt Q&A tối đa trong Sliding Window
  max_context_chars: 1500  # Giới hạn ký tự ngữ cảnh inject vào prompt LLM
```

4.1. Môi trường và cấu hình triển khai

- **Cấu hình mô hình nhúng - BAAI/bge-m3**

Đặc điểm	Giá trị
Số chiều vector	1024 chiều
Phương pháp đo tương đồng	Cosine Similarity
Batch size khi build DB	32
Môi trường thực thi	CPU, không cần GPU

- **Cấu hình mô hình ngôn ngữ lớn**

```
llm:  
  provider: "gemini"           # Đổi thành "ollama" để dùng model cục bộ  
  model_name: "gemini-2.5-flash"  
  temperature: 0.3            # Sáng tạo thấp để đảm bảo tính nhất quán  
  max_tokens: 2048  
  timeout_seconds: 120  
  api_key_env: "GEMINI_API_KEY"
```

5. Kết luận

Kết quả đạt được:

- Xây dựng quy trình ETL xử lý dữ liệu.
- Xây dựng được bộ dữ liệu huấn luyện cho mô hình.
- Huấn luyện tinh chỉnh mô hình.
- Đánh giá và kiểm thử định lượng.

Định hướng phát triển của đề án:

- Cải thiện chất lượng của mô hình.
- Triển khai thực tế và tích hợp hệ thống.
- Mở rộng phạm vi tri thức và đa phương thức.
- Đóng gói và mở rộng sang các cơ sở giáo dục khác.


**Cảm ơn thầy cô và các bạn
đã lắng nghe !**

Phụ Lục

Mẫu dữ liệu huấn luyện

Search this dataset			
instruction	input	output	doc_type
string · lengths	string · lengths	string · lengths	string · classes
			
13118	110881	68500	10 values
Chương trình Cử nhân có thời gian đào tạo chuẩn là bao lâu?	Bạn là chatbot hỏi đáp quy chế sinh viên. Chỉ sử dụng thông tin...	Theo Điều 2, Khoản 6, từ Quy chế đào tạo năm 2025, mình trả lời bạ...	Quy chế đào tạo năm 2025
Sinh viên cử nhân được phép chậm tiến độ tối đa bao nhiêu học kỳ?	Bạn là chatbot hỏi đáp quy chế sinh viên. Chỉ sử dụng thông tin...	Theo Điều 3, Khoản 3, từ Quy chế đào tạo năm 2025, mình trả lời bạ...	Quy chế đào tạo năm 2025
Một tín chỉ tương đương bao nhiêu giờ học tập?	Bạn là chatbot hỏi đáp quy chế sinh viên. Chỉ sử dụng thông tin...	Theo Điều 4, Khoản 1, từ Quy chế đào tạo năm 2025, mình trả lời bạ...	Quy chế đào tạo năm 2025
Điểm tổng kết học phần bao nhiêu thì đạt điểm A?	Bạn là chatbot hỏi đáp quy chế sinh viên. Chỉ sử dụng thông tin...	Theo Điều 5, Khoản 6, từ Quy chế đào tạo năm 2025, mình trả lời bạ...	Quy chế đào tạo năm 2025
Nếu vắng mặt từ 5 buổi trở lên thì bị trừ bao nhiêu điểm quá trình?	Bạn là chatbot hỏi đáp quy chế sinh viên. Chỉ sử dụng thông tin...	Theo Điều 5, Khoản 2, từ Quy chế đào tạo năm 2025, mình trả lời bạ...	Quy chế đào tạo năm 2025

Sơ đồ luồng thuyết kế



Cấu trúc 1 đoạn chunk

```
print(all_chunk[12])
```

```
... page_content='8. Các CTĐT cấp bằng cử nhân, kỹ sư, thạc sĩ, tiến sĩ được công bố công khai trước  
khi tuyển sinh, phù hợp với các quy định hiện hành của Bộ GDĐT và chuẩn CTĐT của  
ĐHBK Hà Nội.  
9. CTĐT có thể được điều chỉnh và áp dụng cho từng khóa tuyển sinh; sinh viên, học  
viên nhập học năm nào sẽ được áp dụng phiên bản chương trình giảng dạy của năm đó.  
Những cập nhật liên quan đến CTĐT của một khóa học chỉ được áp dụng khi không ảnh  
hưởng đến kết quả học tập, rèn luyện đã tích lũy của người học.' metadata={'doc_type': 'Quy chế đào tạo', 'effective_date': '2025-05-28',
```

```
print(all_chunk[11])
```

```
... page_content='| 0 | 1 | 2 | 3 |  
|:-----| :-----|:-----|:-----|  
| Chương trình | Người học | Thời gian | Khối lượng  
| | | | tối thiểu |  
| Cử nhân | Tốt nghiệp THPT | 4 năm | 132 tín chỉ |  
| Kỹ sư | Tốt nghiệp cử nhân theo | 1,5 năm | 48 tín chỉ |  
| | chương trình tích hợp | | |  
| | Tốt nghiệp cử nhân | 2 năm | 60 tín chỉ |  
| Thạc sĩ | Tốt nghiệp cử nhân | 2 năm | 60 tín chỉ |  
| | Tốt nghiệp cử nhân theo | 1,5 năm | 48 tín chỉ |  
| | chương trình tích hợp | | |  
| Tiến sĩ | Tốt nghiệp thạc sĩ | 3 năm | 106 tín chỉ |  
| | Tốt nghiệp đại học | 4 năm | 151 tín chỉ |' metadata={'doc_type': 'Quy chế đào tạo', 'effective_date':
```